

Rapport Technique : Apprentissage Auto-Supervisé avec SimCLR sur CIFAR-10

Projet Deep Learning Encadré par : **Chahiri**

Mai 2026

Contents

1 Introduction

1.1 Contexte

L'apprentissage auto-supervisé est un paradigme d'apprentissage non-supervisé qui exploite les données sans étiquettes. Il a émergé comme une solution prometteuse pour des tâches complexes en vision par ordinateur.

1.2 Problématique

Comment optimiser la qualité des représentations latentes issues de CIFAR-10 en se basant uniquement sur des techniques contrastives tout en assurant de bonnes performances en évaluation supervisée ?

1.3 Objectifs

Les principaux objectifs sont les suivants :

- Concevoir un modèle d'apprentissage basé sur SimCLR optimisé pour CIFAR-10.
- Évaluer les représentations apprises par une approche linéaire supervisée.

2 Méthodologie

2.1 Pipeline SimCLR

SimCLR (Simple Contrastive Learning Representation) repose sur deux composantes principales :

- **Encodage des images** : Utilisation d'un ResNet-18, adapté à des images petites (32x32 pixels pour CIFAR-10).
- **Projection** : Transformation des représentations encodées en vecteurs d'embedding de dimension 128 via un MLP (Multi-Layer Perceptron).

2.2 Augmentations et Transformations

Le modèle SimCLR utilise des schémas d'augmentation des données variés pour obtenir des données corrélées :

- Recadrages aléatoires (Random Cropping).
- Flou gaussien.
- Jitters de couleurs.

Cette stratégie génère deux versions transformées d'une image donnée pour entraîner le modèle.

2.3 Optimisation

La perte contrainte utilisée est la **NT-Xent Loss** (Normalized Temperature-scaled Cross-Entropy Loss), qui cherche à minimiser la distance entre les représentations positives tout en maximisant celle entre négatives.

3 Implémentation

SimCLR a été implémenté avec **PyTorch**. Les principaux fichiers du projet sont :

- **models.py** : Définition de l'architecture.
- **train_simclr.py** : Entraînement avec NT-Xent Loss.
- **eval_linear.py** : Évaluation supervisée en ajoutant un classifieur linéaire.




Figure 1: Visualisation des embeddings via UMAP.

4 Résultats

4.1 Embeddings Visualisés

UMAP et t-SNE sont utilisés pour observer la qualité des représentations produites.




Figure 2: Visualisation des embeddings via t-SNE.

4.2 Courbes de Performance

Les graphiques ci-dessous présentent les métriques clés obtenues durant le fine-tuning :




Figure 3: Perte pendant l'entraînement.




Figure 4: Précision obtenue sur les données de test.

5 Défis et Résolutions

- **Limitation mémoire GPU** : Réduction de la taille des batchs et ajustements de l'optimiseur.
 - **Transformations** : Certaines augmentations (par ex. : flou) ont montré des bénéfices limités.
-

6 Conclusion et Perspectives

6.1 Résumé

Ce projet démontre l'efficacité de SimCLR pour l'apprentissage non-supervisé. Environ 85% de précision est atteinte dans le cadre d'une évaluation supervisée.

6.2 Futurs Travaux

- Utiliser des modèles plus profonds (ex. : ResNet-50).
- Étendre le pipeline à d'autres jeux de données.